

Diseño de un Benchmark y Framework de Evaluación para Robustez Adversarial en Tareas de Razonamiento Verbal en Español

Rodrigo Jose Alva Sáenz

rodrigo.alva@unmsm.edu.pe

Alwin Edu Dávila Raffo

alwin.davila@unmsm.edu.pe

Damaris Marian Del Carpio Martinez

damaris.delcarpio@unmsm.edu.pe

Jesus Stevan Diaz Ingol

jesus.diaz10@unmsm.edu.pe

Paolo Luis Flores Cóngora

paolo.flores2@unmsm.edu.pe

Abstract

La robustez adversarial de los modelos de lenguaje de gran escala ante perturbaciones multilingües permanece como un área poco explorada en español. Presentamos un benchmark de 2,215 ítems de razonamiento verbal y un framework modular de evaluación para medir la robustez de LLMs frente a cinco tipos de perturbaciones adversariales en siete tareas. El sistema integra tres proyectos complementarios: perturbaciones léxicas (sinónimos, pares mínimos, eliminación de atajos), parafrásticas y *cross-lingual* mediante traducción a cinco idiomas (árabe, chino, francés, japonés, ruso). Evaluamos siete modelos de distintas familias y tamaños, reportando siete métricas de robustez: accuracy, accuracy drop (Δ), flip rate, consistencia, transferencia positiva, transferencia negativa y rank consistency (correlación de Spearman sobre logprobs). Los ataques cross-lingual producen mayor degradación que los léxicos en todos los modelos funcionales, con el árabe causando el mayor daño ($\Delta = 7.99\%$ en qwen2.5-coder). El modelo con rendimiento cercano al azar (llama3.2-uncensored, accuracy basal 22.66%) *mejora* bajo todos los ataques cross-lingual (Δ negativo en los cinco idiomas), sugiriendo que la perturbación no degrada lo que ya es esencialmente selección aleatoria. Los valores de rank consistency calculados sobre muestras con logprobs suficientes ($n \geq 30$) se ubican cerca de cero, sin evidencia de inversión sistemática del ranking interno de opciones.

1 Introducción

Los modelos de lenguaje de gran escala han alcanzado un rendimiento sobresaliente en numerosas tareas de procesamiento de lenguaje natural, incluyendo comprensión lectora, razonamiento lógico y generación de texto (Brown et al., 2020; Wei et al., 2022). Sin embargo, gran parte de la investigación sobre su evaluación se ha centrado desproporcionadamente en el inglés, dejando subrepresentadas lenguas con cientos de millones de

hablantes (Köpf et al., 2023).

Un problema fundamental es la falta de estandarización: distintos estudios utilizan datasets heterogéneos, métricas incomparables y configuraciones experimentales inconsistentes, lo que dificulta la comparación justa entre modelos (Liang et al., 2022). A esto se suma la fragilidad adversarial: pequeñas perturbaciones en la entrada pueden provocar fallos inesperados incluso en modelos de alto rendimiento (Wang et al., 2024).

Este trabajo es el Proyecto 3 de una serie de tres proyectos complementarios. Los Proyectos 1 y 2 construyeron datasets adversariales mediante perturbaciones léxicas y parafrásticas. El presente integra esos resultados bajo un framework unificado, añade perturbaciones cross-lingual a cinco idiomas, e implementa métricas de robustez inspiradas en Lim et al. (2025), quienes estudian cómo los procesos latentes específicos de cada lengua limitan la transferencia cross-lingual en LLMs.

Las contribuciones principales son: (1) un dataset de 2,215 ítems de razonamiento verbal en español bajo formato unificado y validado; (2) un framework modular extensible que soporta ataque cross-lingual; (3) siete métricas de robustez, incluyendo rank consistency sobre logprobs; y (4) un análisis de patrones de fallo sobre siete modelos bajo condiciones adversariales controladas.

2 Problemática

La evaluación rigurosa de la robustez adversarial en LLMs enfrenta tres obstáculos fundamentales.

Falta de estandarización. Los estudios existentes utilizan datasets con formatos propietarios, métricas inconsistentes y protocolos no reproducibles (Liang et al., 2022), haciendo que los resultados publicados sean en la práctica incomparables entre sí.

Ausencia de análisis cross-lingual en español. Benchmarks como PromptBench (Wang et al., 2024) o AdvGLUE (Wang et al., 2022) operan casi exclusivamente en inglés. La robustez de LLMs frente a cambios de idioma en tareas de razonamiento verbal en español, en particular para lenguas tipológicamente diversas como el árabe, el japonés o el ruso, no ha sido estudiada de forma sistemática.

Métricas incapaces de distinguir tipos de degradación. Las métricas estándar (accuracy, F1) no capturan si el modelo *mantiene* su conocimiento correcto o *transfiere sus errores* al pasar de la condición base a la adversarial. La rank consistency (Lim et al., 2025) permite detectar reorganizaciones en la distribución de confianza incluso cuando la respuesta final no cambia, revelando vulnerabilidades invisibles para métricas de accuracy sola.

3 Experimental Setup

3.1 Dataset

El dataset base (`processed_dataset.json`) contiene 2,215 ítems de razonamiento verbal en español (la totalidad del banco de preguntas del proyecto), distribuidos en siete tipos de tarea que cubren distintas dimensiones del procesamiento lingüístico (Tabla 1).

Tarea	Ítems
Comprensión lectora (<code>reading_comprehension</code>)	500
Series verbales (<code>verbal_series</code>)	500
Oraciones eliminadas (<code>sentence_elimination</code>)	500
Ordenamiento oraciones (<code>sentence_ordering</code>)	319
Analogías (<code>analogies</code>)	209
Sinónimos/antónimos (<code>synonyms_and_antonyms</code>)	174
Oraciones incompletas (<code>incomplete_sentences</code>)	13
Total	2,215

Table 1: Distribución de ítems por tarea en el dataset base.

Todos los ítems siguen el esquema JSON con índice de respuesta base-0:

```
{
  "id": 0,
  "task": "sentence_ordering",
  "question": "Cuál es el orden
    ↳ lógico...",
  "options": ["0) ...", "1) ...",
    "2) ...", "3) ..."],
  "answer": 3,
  "rationale": "Explicación del
    ↳ razonamiento"
}
```

El campo `rationale` es opcional y no se expone al modelo. El framework valida automáticamente la integridad de cada dataset y alinea los datasets adversariales con el baseline antes de calcular métricas.

Familia 1: Ataques Léxicos (Proyecto 1). La intuición es que un modelo que razona semánticamente, no sobre patrones de superficie, debe mantener su respuesta ante variaciones léxicas que no alteran el significado.

- **Sinónimos (Synonym):** Palabras clave se reemplazan por sinónimos de frecuencia equivalente. Evalúa si el modelo ancla su razonamiento a tokens específicos.
- **Pares mínimos (MinimalPairs):** Se modifica una única palabra crítica (negación, cuantificador, conector) que invierte o altera el significado. Aísla la sensibilidad a elementos de alta carga semántica con mínimo cambio de superficie.
- **Eliminación de atajos (ShortcutRemoval):** Se eliminan conectores lógicos explícitos («porque», «por lo tanto», «primero... luego»). Evalúa si los modelos explotan estas señales superficiales en lugar de construir una representación coherente.

Familia 2: Ataque Parafrástico (Proyecto 2).

- **Paráfrasis (Paraphrasing):** El enunciado se reescribe preservando significado pero alterando forma y estructura sintáctica. Más agresivo que la sustitución léxica, puede cambiar el orden de la información y la organización oracional completa.

Familia 3: Ataque Cross-lingual (Proyecto 3).

Motivados por Lim et al. (2025), evaluamos si los procesos latentes del idioma de la instrucción interfieren con el razonamiento. El ataque CrossLingual traduce el campo `question` dinámicamente a otro idioma mediante `qwen3.6-plus` (OpencodeGo), manteniendo las opciones en español. Se aplica a cinco idiomas con distancias tipológicas crecientes respecto al español:

- **Francés (FR):** Lengua romance; distancia tipológica baja. Control de mínimo impacto esperado.

- **Ruso (RU):** Lengua eslava; escritura cirílica, morfología flexiva. Distancia media-alta.
- **Chino (ZH):** Lengua sino-tibetana; escritura logográfica, morfología aislante. Distancia alta.
- **Japonés (JA):** Escritura mixta (hiragana, katakana, kanji). Distancia alta.
- **Árabe (AR):** Lengua semítica; escritura RTL, morfología radicalmente diferente. Distancia alta.

Las traducciones se validan contra un umbral de longitud mínima del 23% del texto original.

3.2 Métricas de Evaluación

Se definen siete métricas. Las de robustez son dirigidas y se calculan para cada par ataque-vs-baseline y para pares cruzados entre ataques.

Accuracy. $\text{Acc} = \text{correctos} / \text{total}$.

Accuracy Drop (Δ).

$$\Delta = \text{Acc}_{\text{base}} - \text{Acc}_{\text{adv}} \quad (1)$$

Valor positivo indica degradación; negativo indicaría mejora aparente (posiblemente artefacto de tasa de fallo diferencial, ver 4.3).

Flip Rate. Proporción de aciertos en la condición base que se convierten en errores bajo perturbación.

Consistencia. Proporción de ítems con la misma respuesta en ambas condiciones, correcta o no.

Transferencia Positiva (PT). Fracción de aciertos base que se mantienen bajo perturbación.

Transferencia Negativa (NT). Fracción de errores base que se repiten *idénticamente* bajo perturbación (errores persistentes). Un NT alto indica que el modelo no solo falla, sino que falla de la misma manera sistemática bajo perturbación: señal de sesgo estructural más que sensibilidad al idioma.

Rank Consistency (ρ). Correlación de Spearman entre vectores de ranking de opciones construidos a partir de logprobs (Lim et al., 2025). Captura reordenamientos en la distribución de confianza incluso cuando la respuesta final no cambia. Requiere que el proveedor devuelva logprobs por token y un mínimo de 30 muestras con logprobs simultáneamente en baseline y ataque; cuando esta condición no

se cumple, se reporta como «—». En esta evaluación, logprobs se habilitó para nidum-gemma-3, qwen2.5-coder, dolphin3, llama3.2-uncensored y qwen3.5-plus, con cobertura variable debido al muestreo parcial. gemma2:27b y deepseek-v4-flash no disponen de logprobs.

4 Resultados Obtenidos

4.1 Resultados Generales: Accuracy Base

La Tabla 2 presenta la accuracy baseline de los siete modelos evaluados sobre el dataset completo (2,215 ítems).

Los modelos de nube (deepseek-v4-flash, qwen3.5-plus) lideran el rendimiento base (74–82%), pero solo disponen de evaluación baseline parcial debido a límites de tiempo y compute. De los modelos con evaluación adversarial completa, gemma2:27b es el más capaz (53.14%) con cero fallidos de parseo. llama3.2-uncensored obtiene 22.66% con un solo fallo de parseo: su bajo rendimiento es de razonamiento, no de formato, a diferencia de lo observado en ejecuciones previas donde fallos de formato inflaban artificialmente la tasa de errores.

4.2 Resultados por Proyecto

Proyectos 1 y 2: Ataques Léxicos y Parafrástico.

La Tabla 3 presenta los resultados de los ataques léxicos y parafrástico (accuracy base independiente = 61.82%).

`ShortcutRemoval` produce el impacto más bajo de toda la evaluación ($\Delta \leq 0.32\%$ a cualquier intensidad), indicando que los modelos no dependen de los conectores lógicos explícitos para resolver las tareas. `Paraphrasing` presenta el flip rate más alto (16.10%) con Δ moderado (3.03%): el modelo cambia sus respuestas frecuentemente, pero no siempre en la dirección equivocada. `MinimalPairs` satura a partir de intensidad 0.5: los resultados en 0.5 y 1.0 son prácticamente idénticos, lo que sugiere que incluso una sola modificación crítica agota el efecto adversarial de este ataque.

Proyecto 3: Ataques Cross-lingual. La Tabla 4 presenta las métricas de robustez cross-lingual para los cinco modelos con evaluación adversarial.

La Tabla 5 desglosa los resultados de gemma2:27b por tarea y los cinco idiomas de perturbación.

Modelo	n	Acc	read	verb	syn	ord	eli	ana
deepseek-v4-flash	1734	81.55%	82.79%	85.48%	—	88.03%	72.12%	81.60%
qwen3.5-plus (pool:2)	886	74.27%	83.12%	—	—	85.89%	65.31%	—
gemma2:27b	2215	53.14%	74.60%	62.80%	58.05%	43.89%	30.40%	42.58%
nidum-gemma-3-27b	2215	42.62%	59.40%	51.80%	50.57%	32.92%	25.80%	29.19%
qwen2.5-coder-7b	2215	39.64%	60.40%	43.20%	42.53%	27.90%	25.40%	31.10%
dolphin3	2215	31.20%	48.80%	31.60%	34.48%	23.82%	21.00%	22.01%
llama3.2-uncensored	2215	22.66%	25.80%	26.60%	20.11%	19.75%	18.40%	23.44%

Table 2: Accuracy base por modelo y tarea. deepseek y qwen3.5-plus tienen cobertura parcial debido a nuestros límites de tiempo y compute. read = reading_comprehension, verb = verbal_series, syn = synonyms_and_antonyms, ord = sentence_ordering, eli = sentence_elimination, ana = analogies.

Ataque	Int.	Acc.	Δ	FR
Baseline	—	61.82%	—	—
MinimalPairs	0.1	59.60%	+2.24%	11.10%
	0.5	58.17%	+3.65%	13.45%
	1.0	58.17%	+3.66%	13.33%
Paraphrasing	0.5	58.79%	+3.03%	16.10%
ShortcutRemoval	0.1	61.61%	+0.22%	6.85%
	0.5	61.50%	+0.32%	7.61%
	1.0	61.62%	+0.22%	7.49%
Synonym	0.5	56.80%	+2.66%	15.95%

Table 3: Resultados de ataques léxicos y parafrástico (P1/P2). FR = flip rate. Evaluación independiente sobre subconjunto del dataset.

4.3 Análisis de Resultados

Patrón 1: Árabe produce el mayor daño; francés el menor. En los cuatro modelos con mayor capacidad (gemma2:27b, nidum-gemma-3, qwen2.5-coder, dolphin3), el árabe es el idioma de ataque más dañino (gemma2:27b: $\Delta = +5.46\%$; nidum-gemma-3: $\Delta = +4.51\%$; qwen2.5-coder: $\Delta = +7.99\%$; dolphin3: $\Delta = +4.38\%$) y el francés o chino el menos dañino (gemma2:27b: $\Delta = +1.44\%$; nidum-gemma-3: $\Delta = +0.32\%$ chino). El ordenamiento en gemma2:27b es: AR > RU > JA > ZH > FR, no estrictamente coincidente con la distancia tipológica al español. El árabe supera al chino pese a que el chino es tipológicamente más distante, posiblemente porque su escritura RTL introduce ambigüedades adicionales en la tokenización o porque los corpus de preentrenamiento en árabe tienen menor representación que los de chino. llama3.2-uncensored constituye una excepción a este patrón (ver Patrón 3).

Patrón 2: Los ataques cross-lingual superan a los léxicos. El Δ máximo de los ataques léxicos y parafrástico (P1/P2) es 3.66% (MinimalPairs intensidad 1.0). El ataque árabe produce +4.38%

a +7.99% según el modelo, es decir, entre 1.2× y 2.2× mayor degradación. ShortcutRemoval representa el extremo inferior: $\Delta \leq 0.32\%$ a cualquier intensidad, lo que indica que los conectores lógicos explícitos contribuyen marginalmente al rendimiento en estas tareas.

Patrón 3: llama3.2-uncensored mejora bajo todos los ataques cross-lingual. llama3.2-uncensored es el único modelo donde los cinco idiomas de perturbación producen Δ negativo: AR (−0.90%), FR (−2.39%), RU (−2.44%), ZH (−2.57%), JA (−4.02%). Es decir, el modelo obtiene *mayor* accuracy bajo ataque que en baseline. Esto no indica robustez, sino lo contrario: con una accuracy basal de 22.66%, cercana al azar (25% para 4 opciones, 20% para 5), el modelo no tiene un rendimiento significativo que degradar. Las flip rates altas (65–71%) confirman que el modelo cambia sus respuestas con alta frecuencia, pero aproximadamente en igual proporción hacia aciertos y hacia errores. Este patrón es consistente con selección casi aleatoria de opciones, donde la perturbación no empeora ni mejora un razonamiento inexistente.

Patrón 4: Rank consistency cercana a cero. Los valores de ρ calculados sobre muestras con logprobs suficientes ($n \geq 30$) se ubican cerca de cero en todos los casos. El único modelo con cobertura completa de ρ en los cinco idiomas es llama3.2-uncensored, con valores entre −0.06 y 0.11. Esto es coherente con su comportamiento cercano al azar: sin un ranking estable de opciones que preservar, la correlación entre baseline y ataque es nula. Los valores más altos de ρ se observan en nidum-gemma-3/ruso ($\rho = 0.23$, $n = 162$) y dolphin3/árabe ($\rho = 0.22$, $n = 140$), indicando correlación positiva moderada: el modelo mantiene parcialmente su ranking bajo perturbación. En qwen2.5-coder/ruso, $\rho = 0.12$ ($n = 212$), cercano

Modelo	Idioma	Acc.	Δ	FR	Cons.	PT	NT	ρ
gemma2:27b	Árabe	47.67%	+5.46%	32.63%	53.77%	67.37%	38.34%	—
	Ruso	48.80%	+4.33%	27.87%	58.10%	72.13%	42.20%	—
	Japonés	48.98%	+4.15%	30.25%	54.18%	69.75%	36.51%	—
	Chino	50.20%	+2.93%	27.61%	56.57%	72.39%	38.63%	—
	Francés	51.69%	+1.44%	23.70%	60.99%	76.30%	43.64%	—
nidum-gemma-3	Árabe	38.10%	+4.51%	43.54%	42.26%	56.46%	31.71%	—
	Japonés	40.18%	+2.44%	42.27%	40.72%	57.73%	28.09%	0.13
	Ruso	41.13%	+1.49%	39.51%	43.88%	60.49%	31.55%	0.23
	Francés	42.21%	+0.41%	37.08%	45.91%	62.92%	33.28%	—
	Chino	42.30%	+0.32%	38.77%	43.52%	61.23%	30.37%	—
qwen2.5-coder	Árabe	31.65%	+7.99%	49.43%	44.06%	50.57%	39.79%	—
	Japonés	36.70%	+2.93%	37.36%	52.10%	62.64%	45.18%	—
	Ruso	37.65%	+1.99%	34.40%	56.48%	65.60%	50.49%	0.12
	Francés	39.59%	+0.05%	32.00%	53.00%	68.00%	43.16%	—
	Chino	41.35%	−1.72%	33.03%	51.83%	66.97%	41.88%	—
dolphin3	Árabe	26.82%	+4.38%	57.89%	34.72%	42.11%	31.36%	0.22
	Japonés	27.58%	+3.61%	54.27%	35.85%	45.73%	31.36%	0.14
	Ruso	28.08%	+3.12%	52.82%	36.21%	47.18%	31.23%	0.04
	Francés	30.02%	+1.17%	46.89%	38.92%	53.11%	32.48%	—
	Chino	30.25%	+0.95%	50.51%	35.58%	49.49%	29.27%	—
llama3.2-uncs.	Árabe	23.57%	−0.90%	69.72%	26.28%	30.28%	25.10%	−0.06
	Francés	25.06%	−2.39%	64.94%	28.44%	35.06%	26.50%	−0.01
	Ruso	25.10%	−2.44%	70.92%	25.10%	29.08%	23.93%	−0.00
	Chino	25.24%	−2.57%	68.13%	25.19%	31.87%	23.23%	0.11
	Japonés	26.68%	−4.02%	65.94%	26.68%	34.06%	24.52%	−0.06

Table 4: Métricas de robustez cross-lingual por modelo e idioma, ordenadas por Δ descendente dentro de cada modelo. ρ = rank consistency (Spearman sobre logprobs, $n \geq 30$); — = logprobs no disponibles o muestra insuficiente. PT = transferencia positiva; NT = transferencia negativa.

al cero. Los valores de ρ para varios pares modelo-idioma no pudieron calcularse debido a cobertura insuficiente de logprobs ($n < 30$), reportándose como «—» en la Tabla 4.

Patrón 5: sentence_ordering mejora consistentemente bajo perturbación cross-lingual. En gemma2:27b, `sentence_ordering` mejora bajo los cinco idiomas de perturbación: $\Delta = -3.45\%$ (AR), -0.63% (RU), -2.51% (JA), -1.57% (ZH), -7.84% (FR). Una hipótesis es que cuando la instrucción llega en otro idioma, el modelo reduce el procesamiento semántico profundo y se enfoca en señales estructurales: en `sentence_ordering`, el orden lógico puede inferirse de marcadores de cohesión (pronombres, tiempos verbales) que son independientes del idioma de la instrucción. También se observan mejoras menores en `synonyms_and_antonyms` bajo chino (-5.75%) y francés (-3.45%).

Patrón 6: Alta flip rate con Δ negativo en llama3.2-uncensored. Como se observa en el Patrón 3, llama3.2-uncensored presenta flip rates altas (65–71%) bajo todos los ataques, con Δ negativos en los cinco idiomas (-0.90% a -4.02%).

La combinación de alta flip rate con Δ negativo confirma que el modelo cambia sus respuestas frecuentemente, pero con un ligero sesgo hacia aciertos bajo perturbación. El $\rho \approx 0$ (entre -0.06 y 0.11) bajo los cinco idiomas indica que no hay un ranking interno estable que la perturbación pueda reordenar, consistente con selección casi aleatoria.

Patrón 7: Transferencia negativa alta como indicador de sesgo. En gemma2:27b, el NT oscila entre 36.5% y 43.6% según el idioma, indicando que entre 37% y 44% de los errores en baseline se repiten *idénticamente* bajo perturbación. En qwen2.5-coder, el NT bajo ruso alcanza 50.5%: la mitad de todos los errores del modelo son persistentes e independientes del idioma del ataque. Esto sugiere sesgos estructurales preexistentes, como preferencia sistemática por ciertas posiciones de opción, que ninguna perturbación logra alterar.

4.4 Interfaces e Implementación

El framework `llm_verbal_framework` se organiza en cuatro capas.

Capa	de	modelos	(Providers).
Tres	backends	bajo una	interfaz

Tarea	Base Acc	Árabe Acc	Δ	Ruso Acc	Δ	Japonés Acc	Δ	Chino Acc	Δ	Fran. Δ
reading_comp.	74.60%	67.60%	+7.00%	67.80%	+6.80%	68.80%	+5.80%	68.00%	+6.60%	+3.80%
verbal_series	62.80%	54.60%	+8.20%	59.40%	+3.40%	59.40%	+3.40%	62.40%	+0.40%	+1.20%
syn./ant.	58.05%	54.60%	+3.45%	55.75%	+2.30%	59.20%	-1.15%	63.79%	-5.75%	-3.45%
inc._sentences	61.54%	38.46%	+23.08%	61.54%	0.00%	61.54%	0.00%	38.46%	+23.08%	+15.38%
analogies	42.58%	33.97%	+8.61%	34.93%	+7.66%	30.14%	+12.44%	34.45%	+8.13%	+0.96%
sentence_ord.	43.89%	47.34%	-3.45%	44.51%	-0.63%	46.39%	-2.51%	45.45%	-1.57%	-7.84%
sentence_eli.	30.40%	24.60%	+5.80%	25.00%	+5.40%	24.40%	+6.00%	25.40%	+5.00%	+6.80%
Total	53.14%	47.67%	+5.46%	48.80%	+4.33%	48.98%	+4.15%	50.20%	+2.93%	+1.44%

Table 5: Accuracy y accuracy drop por tarea, gemma2:27b (5 idiomas). Δ negativo = mejora bajo ataque. Para francés, solo se muestra Δ por espacio; accuracy base $\times (1 - \Delta)$ para recuperar el valor.

común (complete(messages, response_format) $\rightarrow$ content, tokens, logprobs): Ollama (modelos locales), OpenRouter (modelos propietarios con logprobs) y OpenCodeGo (dual backend: AsyncOpenAI para kimi-k2.6, deepseek-v4-flash, qwen3.5-plus; AsyncAnthropic para modelos Anthropic).

Capa de ataques. CrossLingual genera perturbaciones dinámicamente con validación de longitud. Los demás ataques cargan datasets pre-computados:

```
benchmark = Benchmark(
```

```
    ↪ baseline=Path("processed_dataset.json"),
    attacks=[
        attacks.CrossLingual(
            ↪ language=CrossLingualLanguage.ARABIC,
            attacks.CrossLingual(
                ↪ language=CrossLingualLanguage.RUSSIAN,
                attacks.CrossLingual(
                    ↪ language=CrossLingualLanguage.JAPANESE,
                    attacks.CrossLingual(
                        ↪ language=CrossLingualLanguage.CHINESE,
                        attacks.CrossLingual(
                            ↪ language=CrossLingualLanguage.FRENCH,
                            attacks.Synonym("synonym_1"),
                            ↪ attacks.Paraphrasing("paraphrasing_1"),
                            ↪ attacks.MinimalPairs("negation_flip"),
                            ↪ attacks.ShortcutRemoval("no_shortcuts"),
                        ],
                        models=[...],
                        concurrency=4, base_dir="benchmark",
                    )
                )
            )
        ],
        result = benchmark.run()
        result.save("stats.json")
        result.save("report.md")
    )
```

Resumabilidad y logprobs. El framework guarda resultados parciales tras cada lote medi-

ante escritura atómica (archivo temporal + rename), permitiendo reanudar evaluaciones interrumpidas sin re-procesar trabajo completado. Con logprobs=True y top_logprobs=5, el framework extrae logprobs por opción escaneando tokens de dígito en el output del modelo y calcula ρ sobre los vectores de ranking resultantes.

Capa de reporte. Exportación en JSON (agregados y por muestra) y Markdown con tablas científicas. La evaluación total duró aproximadamente 20 horas combinando dos ejecuciones del benchmark sobre hardware local (Ollama) y APIs en la nube.

5 Conclusiones

Este trabajo presentó un benchmark de 2,215 ítems de razonamiento verbal en español y un framework de evaluación modular para medir la robustez adversarial de LLMs bajo cinco tipos de ataque y cinco idiomas de perturbación. Las contribuciones y hallazgos principales son:

1. Un dataset unificado en formato JSON con siete tipos de tarea, con validación automática de integridad estructural.
2. Un framework reproducible con tres backends de modelo, concurrencia configurable y exportación en múltiples formatos.
3. Siete métricas de robustez incluyendo rank consistency sobre logprobs, que requiere un mínimo de 30 muestras con logprobs simultáneos para producir un valor fiable.
4. La jerarquía de impacto adversarial: ataques cross-lingual dominan sobre léxicos ($\Delta_{AR} \leq 7.99\%$ vs $\Delta_{MinPairs} \leq 3.66\%$); dentro de los cross-lingual, árabe $>$ ruso $\approx$ japonés $>$ chino $>$ francés en los modelos con mayor capacidad. ShortcutRemoval es el ataque

menos efectivo ($\Delta \leq 0.32\%$), lo que indica que los modelos no explotan estos atajos superficiales de manera significativa.

5. Los valores de rank consistency calculados sobre muestras suficientes ($n \geq 30$) se ubican cerca de cero, sin evidencia de inversión sistemática del ranking interno de opciones. La cobertura parcial de logprobs limita el análisis a un subconjunto de pares modelo-idioma.
6. llama3.2-uncensored, con accuracy basal cercana al azar (22.66%), *mejora* bajo todos los ataques cross-lingual (Δ negativo en los cinco idiomas). Esto no indica robustez sino ausencia de razonamiento: la perturbación no puede degradar lo que es esencialmente selección aleatoria.
7. `sentence_ordering` mejora consistentemente bajo todos los idiomas de perturbación en gemma2:27b, sugiriendo que la instrucción en otro idioma favorece un procesamiento más estructural que beneficia a esta tarea en particular.

Como trabajo futuro, se propone completar la evaluación de los modelos de nube con ataques adversariales (deepseek-v4-flash, qwen3.5-plus), extender la cobertura de logprobs a todos los modelos y muestras para habilitar un análisis más robusto de rank consistency, y aplicar análisis de representaciones internas (CKA, activation steering) para contrastar con los hallazgos de [Lim et al. \(2025\)](#).

Agradecimientos

Los autores agradecen al PhD. Marco Antonio Sobrevilla Cabezado, docente del curso de Software Inteligente de la Universidad Nacional Mayor de San Marcos por la orientación brindada durante el desarrollo de este trabajo.

References

- Tom Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared D Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, and 1 others. 2020. Language models are few-shot learners. *Advances in neural information processing systems*, 33:1877–1901.
- Andreas Köpf, Yannic Kilcher, Dimitri von Rütte, Sotiris Anagnostidis, Zhi-Rui Tam, Keith Stevens, Bobby Barres, Micha Natsev, Mantas Slama, and

Thomas Freiberger. 2023. Are multilingual LLMs robust to language variation? In *Proceedings of the 1st Workshop on Cross-Cultural Considerations in NLP*.

Percy Liang, Rishi Bommasani, Tony Lee, Dimitris Tsipras, Dilara Soylu, Michihiro Yasunaga, Yian Zhang, Deepak Narayanan, Yuhuai Wu, Ananya Kumar, and 1 others. 2022. Holistic evaluation of language models. *arXiv preprint arXiv:2211.09110*.

Zheng Wei Lim, Alham Fikri Aji, and Trevor Cohn. 2025. [Language-specific latent process hinders cross-lingual performance](#). *arXiv preprint arXiv:2505.13141*.

Boxin Wang, Chejian Xu, Shuohang Wang, Zhe Gan, Yu Cheng, Jianfeng Gao, Ahmed Hassan Awadallah, and Bo Li. 2022. [Adversarial GLUE: A multi-task benchmark for robustness evaluation of language models](#). In *Thirty-fifth Conference on Neural Information Processing Systems Datasets and Benchmarks Track*.

Kaijie Wang, Jindong Liu, Lifan He, Weiming Xu, Yang Gao, and Xing Xing. 2024. [PromptBench: Towards evaluating the robustness of large language models on adversarial prompts](#). In *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*, pages 4056–4076.

Jason Wei, Yi Tay, Rishi Bommasani, Colin Raffel, Barret Zoph, Sebastian Borgeaud, Dani Yogatama, Maarten Bosma, Denny Zhou, Donald Metzler, and 1 others. 2022. Emergent abilities of large language models. *Transactions on Machine Learning Research*.

A Ejemplos de Perturbaciones por Tipo de Ataque

Los ejemplos se resumen en la Tabla 6.

B Resumen de Modelos y Cobertura

Los modelos evaluados se resumen en la Tabla 7.

Ataque	Enunciado original (ES)	Enunciado perturbado
Base	¿Cuál es sinónimo de «perspicaz»?	—
Synonym	¿Cuál es sinónimo de «sagaz»?	Sustitución léxica; significado preservado.
MinimalPairs	¿Cuál no es sinónimo de «perspicaz»?	Un cambio mínimo invierte el significado.
ShortcutRemoval	¿Cuál corresponde a «perspicaz»?	Eliminación del atajo «sinónimo de».
Paraphrasing	¿Qué palabra tiene el mismo significado que «perspicaz»?	Reescritura sintáctica completa.
CL/FR (francés)	Lequel est synonyme de «perspicaz»?	Traducción al francés; opciones en ES.
CL/ZH (chino)	"perspicaz"	Traducción al chino; opciones en ES.
CL/AR (árabe)	«perspicaz»	Traducción al árabe (RTL); opciones en ES.
CL/JA (japonés)	perspicaz	Traducción al japonés; opciones en ES.
CL/RU (ruso)	«perspicaz»?	Traducción al ruso (cirílico); opciones en ES.

Table 6: Ejemplos de los nueve tipos de perturbación sobre un ítem de sinónimos/antónimos. Las opciones permanecen en español en todos los casos.

Modelo	Prov.	Ataques CL	logprobs
deepseek-v4-flash	OCG	—	No
qwen3.5-plus (pool:2)	mix	parcial	Parcial
gemma2:27b	Oll	AR/RU/JA/ZH/FR	No
nidum-gemma-3-27b	Oll	AR/RU/JA/ZH/FR	Parcial
qwen2.5-coder-7b	Oll	AR/RU/JA/ZH/FR	Parcial
dolphin3	Oll	AR/RU/JA/ZH/FR	Parcial
llama3.2-uncensored	Oll	AR/RU/JA/ZH/FR	Parcial

Table 7: Modelos evaluados, ataques ejecutados y disponibilidad de logprobs para rank consistency. “Parcial” indica que los logprobs se recolectaron solo para un subconjunto de muestras, por lo que algunos pares modelo-idioma no alcanzan el mínimo de $n = 30$ para ρ . qwen3.5-plus dispone de evaluación CL parcial ($n = 308\text{--}476$ por idioma) debido a límites de compute. OCG = OpencodeGo, Oll = Ollama, mix = pool Ollama+OpencodeGo.